

Avaliando a generalização

Alberto Paccanaro
EMAp – FGV

www.paccanarolab.org

Alguns materiais e imagens são de (ou adaptados de):

C. Bishop, Reconhecimento de Padrões e Aprendizado de Máquina, Springer, 2006

A. Geron , aprendizado de máquina prático com Scikit-Learn, Keras e TensorFlow, O'Reilly, 2020

Conteúdo

- Training/validation/test set
- Como medir o desempenho da generalização
 - a) Regressão
 - b) Classificação

O problema

Depois que o sistema aprender, estamos interessados em avaliar o quão bem ele funcionará no futuro, em **novos** datapoints.


Como podemos avaliar isso ???



Não use todos os dados para treinamento.

Reserve uma parte de seus dados e use-os como se fossem dados "futuros".

Conjunto de treinamento, conjunto de teste




TREINAMENTO

	feature 1	feature 2		feature p	TARGET
Datapoint 1	$x_{1,1}$	$x_{1,1}$	...	$x_{1,p}$	t_1
Datapoint 2	$x_{2,1}$	$x_{2,2}$	...	$x_{2,p}$	t_2
Datapoint 3	$x_{2,1}$	$x_{2,2}$	...	$x_{2,p}$	t_3
	...	...	...	...	...
Datapoint N-1	$x_{N-1,1}$	$x_{N-1,2}$	...	$x_{N-1,p}$	t_{N-1}
Datapoint N	$x_{N,1}$	$x_{N,2}$	...	$x_{N,p}$	t_N

TESTE

Essa ideia é boa, mas apenas usar conjuntos de treinamento e teste é incorreto, porque...

já falamos sobre 2 tipos de parâmetros!...



Praticamente em qualquer modelo de aprendizado de máquina você terá 2 tipos de parâmetros:

1. Parâmetros que o algoritmo ajustará durante o treinamento (w)
2. Parâmetros que precisam ser definidos pelo usuário (estes decidem a *forma* do seu modelo)

Objetivo: **GENERALIZAÇÃO !**

Deixar de lado um conjunto de teste não é suficiente... ☹

Conjunto de treinamento, conjunto de validação, conjunto de teste

	feature 1	feature 2		feature p	TARGET
Datapoint 1	$x_{1,1}$	$x_{1,1}$	...	$x_{1,p}$	t_1
Datapoint 2	$x_{2,1}$	$x_{2,2}$	...	$x_{2,p}$	t_2
Datapoint 3	$x_{2,1}$	$x_{2,2}$	...	$x_{2,p}$	T_3
	...	...	...	...	...
Datapoint 3	$x_{2,1}$	$x_{2,2}$	...	$x_{2,p}$	T_3
Datapoint 3	$x_{2,1}$	$x_{2,2}$	...	$x_{2,p}$	T_3
	...	...	...	...	...
Datapoint N-1	$x_{N-1,1}$	$x_{N-1,2}$	...	$x_{N-1,p}$	t_{N-1}
Datapoint N	$x_{N,1}$	$x_{N,2}$	...	$x_{N,p}$	t_N


Como usar os conjuntos de treino, validação e teste

1. Escolha um conjunto de parâmetros da forma do modelo
2. Treine o modelo (ou seja, use o algoritmo de aprendizado de máquina para encontrar um bom conjunto de pesos w para os parâmetros escolhidos em 1.)
3. Teste o desempenho no conjunto de validação
4. Repita as etapas 1-3 para todos os conjuntos de parâmetros da forma do modelo que desejar
5. Selecione o conjunto de parâmetros da forma do modelo que proporcionou o melhor desempenho no conjunto de validação.
6. Junte os conjuntos de treino e validação e use esse conjunto para treinar um modelo com os parâmetros que você escolheu em 5
7. Meça o desempenho no conjunto de testes. Este é o desempenho do seu sistema.

... e se eu não tiver dados suficientes para os conjuntos de treino, validação e teste...

Crossvalidation

- 1) Particionar dados em S grupos
- 2) Use $(S-1)$ grupos para treinamento e um grupo para teste
- 3) Repita o passo 2) S vezes
- 4) Faça a média das pontuações de desempenho dos S conjuntos de teste



Quando $S = N$ (tamanho do conjunto de dados) é chamado de Leave-one-out (LOO)

Como medir o desempenho da generalização

Os problemas de regressão e classificação são diferentes

- **Problemas de regressão:** as coisas são bastante simples, pois só precisamos medir o quão longe estamos, em média, do resultado correto.
- **Problemas de classificação:** mais complicados por duas razões
 1. a saída do meu sistema é um valor que eu tenho que interpretar como o rótulo de uma classe e, dependendo de como eu interpretá-lo, podemos ter resultados diferentes
 2. pode haver uma diferença na gravidade do erro, dependendo de quais classes você troca

Problemas de regressão

Pegamos um conjunto de teste de N pontos e medimos:

Sum-of-Squares Error (SSE):

$$E_{SSE}(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N (y_n - t_n)^2$$

Root-mean-square error (RMS):

$$E_{RMS}(\mathbf{w}) = \sqrt{\frac{\sum_{n=1}^N (y_n - t_n)^2}{N}}$$

$$E_{RMS}(\mathbf{w}) = \sqrt{\frac{2 E_{SSE}(\mathbf{w})}{N}}$$

Classification problems

MNIST

70.000 imagens

Cada imagem:
matriz 28x28

Cada pixel pode
assumir valores em
[0, 255]



1. Classificação binária

PROBLEMA: Queremos construir um “detector-de-5” capaz de distinguir entre apenas duas classes,

- 5 (C_1 ou “positivos”, P)
- não-5 (C_0 ou “negativos”, N).

**Vamos supor que construímos nosso classificador.
Como posso avaliar seu desempenho no conjunto de teste?**

Lembre-se: estamos sempre interessados em generalização, ou seja, quão bem ele funcionará em dados não vistos (que é o conjunto de teste)

Matriz de confusão

Saída do classificador: valor entre 0 e 1




Escolhemos um limiar τ (threshold)

		REAL	
		positivo (P)	negativo (N)
PREVISTO	positivo	TP	FP <i>Erro tipo 1 (alarme falso)</i>
	negativo	FN <i>Erro tipo 2 (falha)</i>	TN

Matriz de Confusão

		REAL	
		positivo (P)	negativo (N)
PREVISTO	positivo	TP	FP
	negativo	FN	TN



Medidas

		REAL	
		positivo (P)	negativo (N)
PREVISTO	positivo	TP	FP
	negativo	FN	TN

$$\frac{TP + TN}{TP + TN + FP + FN}$$

Acurácia : porcentagem de previsões corretas

$$\frac{TP}{TP + FP}$$

Precision (precisão): a acurácia das previsões positiva (*quão preciso eu sou? Qual é a % de previsões corretas de todas as que prevejo como P?*)

$$\frac{TP}{P} = \frac{TP}{TP + FN}$$

Recall (or sensitivity): porcentagem de positivos que são previstos corretamente (*quanto eu “cobri” o P?*)

$$\frac{TN}{N} = \frac{TN}{TN + FP}$$

Specificity: porcentagem de negativos que são previstos corretamente (*quanto eu “cobri” o N?*)

Infelizmente: aumentar a precisão reduz o recall e vice-versa...

PANBIO™ COVID-19 Ag RAPID TEST DEVICE

VISÃO GERAL

BENEFÍCIOS

INFORMAÇÕES DETALHADAS



INFORMAÇÕES DETALHADAS

DOCUMENTOS ÚTEIS

ESPECIFICAÇÕES

- ✓ Tempo de teste: 15 minutos
- ✓ Swab nasal x PCR nasal:
Sensibilidade de 98,1% (99,0% para amostras com valores $Ct \leq 33$)/Especificidade de 99,8%.
- ✓ Swab nasal x PCR nasofaríngeo:
Sensibilidade de 91,1%/Especificidade de 99,7%
- ✓ Swab nasofaríngeo x PCR nasofaríngeo:
Sensibilidade de 91,4% (94,1% para amostras com valores $Ct \leq 33$)/Especificidade de 99,8%.
- ✓ Armazenamento: 2 °C a 30 °C

Trade-off precisão/recall



Pontuação F_1

$$HM(x_1, \dots, x_n) = \frac{n}{\frac{1}{x_1} + \dots + \frac{1}{x_n}}$$


A média harmônica de precisão e recall:

$$F_1 = \frac{2}{\frac{1}{\text{precision}} + \frac{1}{\text{recall}}} = 2 \times \frac{\text{precision} \times \text{recall}}{\text{precision} + \text{recall}} = \frac{TP}{TP + \frac{FN + FP}{2}}$$

É maior quando a precisão e o recall são altos.

Essas considerações nos ajudam a escolher um threshold.
Posso usar essas ideias para comparar o desempenho dos classificadores?

A curva receiver operating characteristic (ROC)



True Positive Rate (TPR)

Taxa de verdadeiro positivo (recall) : % de positivos que são previstos corretamente

$$\frac{TP}{P} = \frac{TP}{TP + FN}$$


False Positive Rate (FPR)

Taxa de falsos positivos :
% de negativos que são previstos incorretamente.

$$\frac{FP}{N} = \frac{FP}{FP + TN}$$

Calculamos esses valores para diferentes valores do limiar τ

- Para diferentes valores do limiar τ obtemos diferentes matrizes de confusão.
- Para cada matriz de confusão calculamos TPR e FPR e esse é um ponto na curva ROC




$$\text{TPR} = \text{TP}/\text{P}$$

$$\text{FPR} = \text{FP}/\text{N}$$

PROPRIEDADES

1. Limitado no quadrado $[0-1]$ do primeiro quadrante
2. Sempre começa em $(0,0)$
3. Sempre termina em $(1,1)$
4. Melhor ponto em $(0,1)$
5. Desempenho aleatório na diagonal principal




Uma maneira de comparar classificadores é medir a *área sob a curva* (AUC).

Um classificador puramente aleatório terá um ROC AUC igual a 0,5.

2. Classificação multiclasse

A matriz de confusão é mais complexa



Classificação Multilabel : várias classes para cada instância.

Vários tipos de medidas foram desenvolvidas para problemas específicos que refletem a natureza e o nosso conhecimento do problema