


Introduzindo o uso de probabilidades – Teoria da Decisão

Alberto Paccanaro
EMap – FGV


www.paccanarolab.org

O material e as imagens nestes slides são de (ou adaptados de):
C. Bishop, Reconhecimento de Padrões e Aprendizado de Máquina, Springer, 2006

Para lembrar, antes de começarmos...



Dois pontos importantes do exemplo de ajuste polinomial (Bishop, cap. 1):




	$M = 0$	$M = 1$	$M = 6$	$M = 9$
w_0^*	0.19	0.82	0.31	0.35
w_1^*		-1.27	7.99	232.37
w_2^*			-25.43	-5321.83
w_3^*			17.37	48568.31
w_4^*				-231639.30
w_5^*				640042.26
w_6^*				-1061800.52
w_7^*				1042400.18
w_8^*				-557682.99
w_9^*				125201.43



Polinômios mais flexíveis estão se tornando cada vez mais sintonizados com o ruído aleatório nos valores-alvo t :
OVERFITTING

COMO PODEMOS CORRIGIR O OVERFITTING?

(1) Vamos aumentar o conjunto de dados



*grau do
polinômio = 9*



Quanto maior o conjunto de dados, mais complexo o modelo que podemos ajustar aos dados.

(2) Regularização

Estimulamos os pesos a serem pequenos!

Adicionamos um termo de penalidade à função de erro:



$$\tilde{E} = E_D(\mathbf{w}) + \lambda E_w(\mathbf{w})$$

λ controla a importância da regularização

$E_D(\mathbf{w})$ é o erro relacionado aos dados (D)


$E_w(\mathbf{w})$ é o "erro" (penalidade) relacionado ao tamanho dos pesos ($\mathbf{w}$)

$$M = 9$$



	$\ln \lambda = -\infty$	$\ln \lambda = -18$	$\ln \lambda = 0$
w_0^*	0.35	0.35	0.13
w_1^*	232.37	4.74	-0.05
w_2^*	-5321.83	-0.77	-0.06
w_3^*	48568.31	-31.97	-0.05
w_4^*	-231639.30	-3.89	-0.03
w_5^*	640042.26	55.28	-0.02
w_6^*	-1061800.52	41.32	-0.01
w_7^*	1042400.18	-45.95	-0.00
w_8^*	-557682.99	-91.53	0.00
w_9^*	125201.43	72.68	0.01

(sem regularização)



A regularização teve um efeito semelhante ao aumento do número de pontos! (overfitting reduzido)

... vamos passar para o tópico de hoje.

Por que probabilidade?


→ Incerteza

De onde isso vem?

1. ruído nas medições
2. tamanho finito de conjuntos de dados

A teoria da probabilidade fornece uma estrutura para lidar com a incerteza

Problema



Probabilidade de um evento: fração de vezes que esse evento ocorre do número total de tentativas (N), por $N \rightarrow \infty$

Perguntas:

1. qual é a probabilidade geral de colher uma maçã?
2. dado que escolhi uma laranja, qual é a probabilidade de que a tenha escolhido da caixa vermelha?

Teorema de Bayes


$$p(Y|X) = \frac{p(X|Y)p(Y)}{p(X)}$$

O denominador no teorema de Bayes é uma constante de normalização:

$$p(Y|X) = \frac{p(X|Y)p(Y)}{\sum_Y p(X|Y)p(Y)}$$

posterior $\propto$ likelihood $\times$ prior

... e de volta à caixa de frutas



Duas variáveis: F (fruta) pode ser a (pple) ou o (range)
 B (caixa) pode ser r (ed) ou b (lue)

Perguntas:

1. qual é a probabilidade geral de colher uma maçã?
2. dado que escolhi uma laranja, qual é a probabilidade de que a tenha escolhido da caixa vermelha?

$$1. P(F = a)$$

$$2. P(B = r \mid F = o)$$

$$p(X) = \sum_Y p(X, Y)$$

$$p(X, Y) = p(Y|X)p(X)$$

$$p(Y|X) = \frac{p(X|Y)p(Y)}{p(X)}$$

$$\begin{aligned} p(B = r) &= ? \\ p(B = b) &= ? \end{aligned}$$

$$\begin{aligned} p(F = a|B = r) &= ? \\ p(F = o|B = r) &= ? \\ p(F = a|B = b) &= ? \\ p(F = o|B = b) &= ? \end{aligned}$$

$$p(F = a) = p(F = a|B = r)p(B = r) + p(F = a|B = b)p(B = b)$$

$$p(B = r|F = o) = \frac{p(F = o|B = r)p(B = r)}{p(F = o)}$$

9/20

2/3

Teorema de Bayes, posterior probability, prior probability

Voltemos à segunda pergunta: “*dado que escolhi uma laranja, qual a probabilidade de que a tenha tirado da caixa vermelha?*”

Antes de saber a identidade da fruta selecionada, minha melhor resposta teria sido $p(B)$, que é chamada **prior probability** porque é a probabilidade disponível *antes* observamos a identidade da fruta.

Uma vez que me digam que a fruta é uma laranja, podemos então usar o teorema de Bayes para calcular a probabilidade $p(B|F)$, que é chamada **posterior probability** porque é a probabilidade obtida *após* nós observamos F

$$p(Y|X) = \frac{p(X|Y)p(Y)}{p(X)}$$

$$p(B = r|F = o) = \frac{p(F = o|B = r)p(B = r)}{p(F = o)}$$

Densidades de probabilidade

Probabilidades em relação a variáveis contínuas

A probabilidade de uma variável de valor real x cair no intervalo $(x, x + \delta x)$ é dada por $p(x) \delta x$ para $\delta x \rightarrow 0$


$p(x)$ é a *densidade de probabilidade* sobre x

Propriedades: $p(x) \geq 0$



$$\int_{-\infty}^{\infty} p(x) dx = 1$$

distribuição cumulativa
(probabilidade de que x está no intervalo $(-\infty, z)$)

$$P(z) = \int_{-\infty}^z p(x) dx$$



A distribuição gaussiana



$$\mathcal{N}(x|\mu, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{1/2}} \exp \left\{ -\frac{1}{2\sigma^2} (x - \mu)^2 \right\}$$

$$\mathcal{N}(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{D/2}} \frac{1}{|\boldsymbol{\Sigma}|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}$$

***Teoria da decisão** para nos dizer como tomar decisões ótimas dadas as probabilidades apropriadas.*

A questão



Temos uma imagem de raio X de um paciente ($\mathbf{x}$), e desejamos determinar se o paciente tem câncer ou não (C_1 ou C_2).

$$p(C_k|\mathbf{x}) = \frac{p(\mathbf{x}|C_k)p(C_k)}{p(\mathbf{x})}$$

Uma vez que eu tenha obtido $p(C_k|\mathbf{x})$ para C_1 e C_2 , como devo decidir sobre a classe, dada a imagem $\mathbf{x}$?

Nossa intuição: para minimizar a chance de atribuir $\mathbf{x}$ à classe errada, escolha a classe com maior probabilidade posterior. *Mas, por que é a coisa correta a fazer?*

Um problema de classificação simples com apenas uma feature




x	target
2	"b"
1.5	"b"
0.5	"a"
0.8	"b"
...	...

Feature x : proporção entre a altura de um caractere e sua largura

Pergunta: como será a distribuição de x para as 2 classes?

“a” $\rightarrow C_1$, “b” $\rightarrow C_2$

Um erro ocorre quando um vetor $\mathbf{x}$ pertencente à classe C_1 é atribuído à classe C_2 ou vice-versa.



$$\begin{aligned} p(\text{mistake}) &= p(\mathbf{x} \in \mathcal{R}_1, C_2) + p(\mathbf{x} \in \mathcal{R}_2, C_1) \\ &= \int_{\mathcal{R}_1} p(\mathbf{x}, C_2) d\mathbf{x} + \int_{\mathcal{R}_2} p(\mathbf{x}, C_1) d\mathbf{x} \end{aligned}$$

$p(\mathbf{x}, C_k) = p(C_k | \mathbf{x}) p(\mathbf{x})$, portanto...

a probabilidade mínima de cometer um erro é obtida se cada valor de $\mathbf{x}$ for atribuído à classe para a qual a probabilidade posterior $p(C_k | \mathbf{x})$ é maior

Minimizando a perda esperada

Função de custo: medida da perda incorrida nas decisões.
Nosso objetivo: minimizar a perda total.

L matriz de perda, onde $L_{k,j}$ perda que incorremos quando classificamos algo da classe k (*classe verdadeira*) como classe j (*classe predita*).

		predito	
		cancer	normal
real	cancer	0	1000
	normal	1	0


ODA FGV

Para minimizar a perda esperada, atribua cada novo ponto de dados $\mathbf{x}$ à classe j para a qual a quantidade:

$$\sum_k L_{kj} p(C_k | \mathbf{x})$$

é mínima.

Opção de Rejeição



Pode haver regiões onde estamos muito incertos sobre a associação de classe. Pode ser apropriado evitar tomar decisões.

Três abordagens para classificação


1. **Modelos generativos:** Inferir $p(\mathbf{x} | C_k)$ e $p(C_k)$ para cada classe. Use-os para encontrar $p(\mathbf{x})$. Use o teorema de Bayes para inferir $p(C_k | \mathbf{x})$. Use a teoria da decisão para determinar a classe para um novo $\mathbf{x}$.

Aqui você modela a distribuição de entradas e saídas. Através da amostragem deles é possível *gerar* pontos de dados sintéticos no espaço de entrada.

2. **Modelos discriminativos:** Inferir $p(C_k | \mathbf{x})$ diretamente. Use a teoria da decisão para determinar a classe para um novo $\mathbf{x}$.
3. **Função discriminante:** aprenda uma função $f(\mathbf{x})$, que mapeia cada entrada $\mathbf{x}$ diretamente em um rótulo de classe. As probabilidades não desempenham nenhum papel.

Considerações

- Abordagem 1) é a mais exigente, você precisa obter a distribuição sobre $\mathbf{x}$ e C_k . Se $\mathbf{x}$ tem alta dimensionalidade, precisamos de muitos dados para obter $p(\mathbf{x}|C_k)$.
- Em 1), ter $p(\mathbf{x})$ pode ser útil para detecção de outliers
- Às vezes só queremos tomar decisões, então realmente só precisamos dos posteriors $p(C_k|\mathbf{x})$.




- A abordagem 3) é a mais simples, mas não temos acesso a $p(C_k|\mathbf{x})$.

Por que é importante ter $p(C_k | x)$?

- A. **Minimizar o risco** – incluir elementos da matriz de perdas é trivial. Incluir revisões da matriz de perdas.
- B. **Opção de Rejeição**
- C. **Compensação de class priors** – isso nos permite aprender com conjuntos de dados balanceados e então compensar o desequilíbrio de classe em dados do mundo real.
- D. **Combinação de modelos** – para aplicações complexas, podemos dividir o problema em subproblemas menores e depois combinar os posteriores.

Teoria da Decisão

REGRESSÃO



A função $y(x)$, que minimiza a perda quadrada esperada, é dada pela média da distribuição condicional $p(t|\mathbf{x})$.


O algoritmo K-nearest-neighbour (ou K-nearest neighbour, KNN, K-NN, Knn, K-nn)

classificação

... nada a ver com o algoritmo k-means...

Problema: determinar a classe para a cruz

Ideia: determine a identidade da cruz usando pontos próximos do conjunto de treinamento.





O algoritmo KNN

Conjunto de dados : N datapoints
pertencentes a L classes

Escolha: $K > 0$

Para classificar uma nova observação
de teste $\mathbf{x}_0$:

- identifique os K pontos vizinhos nos dados de treinamento que estão mais próximos de $\mathbf{x}_0$ -- chame este conjunto de pontos N_0
- para cada classe j , calcule a fração F_j de pontos em N_0 cujos rotulos sejam iguais a j
- classifique a observação de teste $\mathbf{x}_0$ para a classe com o maior F_j



Perguntas para vocês

1. Pera aí... mas afinal, **quais são os parâmetros** que a gente tá aprendendo aqui???
2. **Quais parâmetros controlam a complexidade do modelo? O modelo pode fazer overfit? Como?**
3. **Existe um modelo probabilístico subjacente? Você pode explicar em termos de probabilidades o que estamos fazendo quando aplicamos esse algoritmo?**