

Definições importantes, visão geral e uma taxonomia de aprendizado de máquina

Alberto Paccanaro
EMap – FGV

<https://paccanarolab.org>


Alguns materiais e imagens são de (ou adaptados de):

C. Bishop, Reconhecimento de Padrões e Aprendizado de Máquina, Springer, 2006

A. Geron, aprendizado de máquina prático com Scikit-Learn, Keras e TensorFlow, O'Reilly, 2020

Aprendizagem supervisionada: **classificação**

Conjunto de dados MNIST: 70.000 exemplos, coletados de funcionários do Census Bureau e alunos do ensino médio.



Para cada imagem, temos também a identidade correta do dígito

Cada dígito corresponde a uma imagem de 28×28 pixels.


Os valores de pixel variam de 0 (preto) a 255 (branco), que geralmente é escalado no intervalo $[0,1]$.

OBJETIVO: construir um sistema que recebe uma imagem como entrada e que produz a identidade do dígito $0, \dots, 9$ como saída.

Regras “artesaniais” para distinguir os dígitos com base nas formas dos traços não funcionam...


Cada dígito (imagem de 28×28 pixels) pode ser representado por um vetor x de 784 números reais - a entrada para o meu sistema

Queremos construir um sistema que...




As entradas são **vetores** $x_i = x_{i,1}, x_{i,2}, \dots x_{i,p}$

NOMENCLATURA



Aprendizagem supervisionada: regressão

Previsão da temperatura ao meio-dia, no Rio, amanhã



A ideia geral (Aprendizagem Supervisionada)

Um conjunto de dados (treinamento) é usado para ajustar os parâmetros de um **modelo adaptativo** (uma função com parâmetros).

GENERALIZAÇÃO

Para cada dígito no conjunto de treinamento, sua categoria é conhecida e representada por um *alvo* $\mathbf{t}$ (vetor ou escalar)

O **resultado** do algoritmo de aprendizado de máquina é:

*uma função $f_w(x)$ que recebe uma **nova** imagem de dígito x como entrada e que gera uma saída y (codificada da mesma forma que $\mathbf{t}$) indicando a classe prevista de x*

Assim, dado o conjunto de dados:

- (1) escolhemos um modelo (a *forma geral* de f_w)
- (2) ajustamos (**aprendemos**) os parâmetros de f_w usando os dados
- (3) usamos o modelo aprendido f_w para fazer previsões


	feature 1	feature 2	...	feature p	TARGET
DP 1	$x_{1,1}$	$x_{1,2}$	...	$x_{1,p}$	t_1
DP 2	$x_{2,1}$	$x_{2,2}$	...	$x_{2,p}$	t_2
DP 3	$x_{3,1}$	$x_{3,2}$	...	$x_{3,p}$	t_3
	...	...	...	...	...
DP N-1	$x_{N-1,1}$	$x_{N-1,2}$	...	$x_{N-1,p}$	t_{N-1}
DP N	$x_{N,1}$	$x_{N,2}$	...	$x_{N,p}$	t_N

*Estou esquecendo alguma coisa?
Uma suposição importante?*

GENERALIZAÇÃO

Os dados que eu uso para treinamento devem ser "semelhantes" àqueles sobre os quais terei que fazer previsões no futuro.

Importante: eu escolho a forma da função! (voltaremos a isso)



A função que é calculada depende de um conjunto de parâmetros w

$$f_w(x) \rightarrow y$$

Aprendizagem: usar os dados (que tenham targets) para ajustar os parâmetros w para que a função calculada seja a que resolve o problema.


Learning from data

A computer program is said to learn from experience E with respect to some task T and some performance measure P , if its performance on T , as measured by P , improves with experience E .

Tom Mitchell, 1997

Diz-se que um programa de computador aprende com a experiência E em relação a alguma tarefa T e alguma medida de desempenho P , se seu desempenho em T , conforme medido por P , melhora com a experiência E .

MENSAGEM CHAVE




Para entender bem isso, vamos analisar um problema mais simples, com apenas uma feature...

autoestudo

O ajuste de uma curva polinomial (Bishop, chapter 1)

Terminologia/conceitos

- Pré-processamento
- Extração das features
- Fase de treinamento ou aprendizado
- Generalização



Outra Suposição fundamental: existe algum tipo de *relação subjacente* entre as features e os valores a ser previstos.

SUPOSIÇÕES CRUCIAIS

1. Existe algum tipo de relação subjacente entre as features e os valores a serem previstos. Estamos tentando obter um f_w que se aproxime dessa relação.
2. Os dados que eu uso para treinamento devem ser "semelhantes" àqueles sobre os quais terei que fazer previsões no futuro [data points that are drawn ~~independently~~ from the same distribution, ~~independent~~ *and identically distributed (i.i.d)*]

Tipos de algoritmos/sistemas de aprendizado de máquina

1. com base no **tipo de dados**
2. com base em **como os dados são processados**
3. com base em como as funções aprendidas **generalizam**

1. Com base no tipo de dados

A. Aprendizagem Supervisionada

Entrada	Target
x_1	t_1
x_2	t_2
$\dots$	$\dots$
x_N	t_N

Dois tipos de problemas:

- a) classificação
- b) regressão

x é um vetor de features $x = (feature_1, feature_2, \dots, feature_n)$

t também pode ser um vetor


B. Aprendizagem não supervisionada

Entrada
x_1
x_2
$\dots$
x_N

Exemplos de problemas:


- a) clustering
- b) detecção de anomalias

x é um vetor de feature $x = (feature_1, feature_2, \dots, feature_n)$



C. Aprendizagem semi-supervisionada

Entrada	Target
x_1	t_1
x_2	t_2
x_3	--
x_4	--
x_5	t_5
...	...
x_N	t_N



x é um vetor de feature $x = (feature_1, feature_2, \dots, feature_n)$
 t também pode ser um vetor

D. Aprendizagem por Reforço

- Agente
- sequência de **estados** e **ações** em que o algoritmo de aprendizagem interage com o ambiente
- somente no final uma recompensa é alcançada.
- *Problema de atribuição de crédito* : a recompensa deve ser atribuída apropriadamente a todas as ações que levaram a ela (bons e ruins)




imagem da Wikipédia

2. Com base em como as funções aprendidas generalizam


A. Aprendizagem baseada em instância:

generalização alcançada usando uma medida de similaridade para comparar novas instâncias com datapoints existentes.



B. Aprendizagem baseada em modelo:

use o conjunto de dados para construir um modelo e, em seguida, use esse modelo para fazer previsões.



3. Com base em como os dados são processados

- A. Aprendizagem em batch (lote):** o sistema é treinado usando dados existentes. Normalmente feito offline (aprendizagem offline)
- B. Aprendizado online:** você treina o sistema de forma incremental, alimentando-o com instâncias de dados sequencialmente. Para sistemas que recebem dados como um fluxo contínuo (por exemplo, preços de ações)