

Modelos lineares para regressão

Alberto Paccanaro

EMap – FGV

<https://paccanarolab.org>

O material e as imagens nestes slides são de (ou adaptados de):

C. Bishop, Reconhecimento de Padrões e Aprendizado de Máquina, Springer, 2006

O problema de regressão

Prever o valor de variáveis *de output* **t contínuas** dado o valor de um vetor *D -dimensional* **$\mathbf{x}$** de variáveis *de input*.

Dadas N observações $\{\mathbf{x}_n\}$, onde $n = 1, \dots, N$, juntamente com os valores de destino $\{t_n\}$ correspondentes, o objetivo é prever o valor de **t** para um novo valor de $\mathbf{x}$.

$\mathbf{x}_n$ é um **vetor** (de D features), $\mathbf{x}_n \in \mathbb{R}^D$
Vamos começar com $t \in \mathbb{R}$

Roadmap

Modelamos a distribuição preditiva $p(t|\mathbf{x})$ expressando nossa incerteza sobre o valor de t para cada valor de $\mathbf{x}$.

- aprender $p(t|\mathbf{x})$ minimizando uma função de erro.
- escolha comum da função de erro para variáveis de valor real: Soma dos Erros Quadrados – **consequência da maximização da verossimilhança sob a suposição de uma distribuição de ruído Gaussiana.**
 - ➔ a solução ótima é dada pela expectativa condicional de t (da teoria da decisão)

Modelos lineares: funções lineares dos parâmetros ajustáveis

IMPORTANTE: pode ser não linear em relação às variáveis de entrada (por exemplo, o polinômio que vimos anteriormente)

- Modelos mais simples: os modelos também são funções lineares das variáveis de entrada.
- *basis functions*: funções não lineares das variáveis de entrada, das quais tomamos combinações lineares

Regressão por combinação linear de funções de base

- Modelo linear mais simples para regressão (muitas vezes chamado apenas *de regressão linear*):

$$y(\mathbf{x}, \mathbf{w}) = w_0 + w_1x_1 + \dots + w_Dx_D = w_0 + \sum_{i=1}^D w_ix_i$$

- combinações lineares de funções de base ~~não lineares~~ fixas, $\phi_j(\mathbf{x})$:

$$\phi_j : \mathbb{R}^D \rightarrow \mathbb{R}$$

$$y(\mathbf{x}, \mathbf{w}) = w_0 + \sum_{j=1}^{M-1} w_j\phi_j(\mathbf{x})$$

As funções de base não lineares permitem que $y(\mathbf{x}, \mathbf{w})$ seja não linear !


- w_0 , chamado parâmetro **bias**, pode ser incluído na soma, definindo uma função de base extra $\phi_0(\mathbf{x}) = 1$

$$y(\mathbf{x}, \mathbf{w}) = \sum_{j=0}^{M-1} w_j\phi_j(\mathbf{x}) = \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x})$$

$$\boldsymbol{\phi} : \mathbb{R}^D \rightarrow \mathbb{R}^M$$


Basis functions *clássicas*

Nota: as ilustrações referem-se a $x \in \mathbb{R}$.




Polinomial

$$\phi_j(x) = x^j$$



gaussiano

$$\phi_j(x) = \exp \left\{ -\frac{(x - \mu_j)^2}{2s^2} \right\}$$



sigmoidal

$$\phi_j(x) = \sigma \left(\frac{x - \mu_j}{s} \right)$$

$$\sigma(a) = \frac{1}{1 + \exp(-a)}$$

μ_i controla as localizações das basis functions
 s controla a escala da basis function

Vamos ver isso de uma perspectiva probabilística

$$\mathbf{x} \equiv (x_1, \dots, x_N)^T$$

$$\mathbf{t} \equiv (t_1, \dots, t_N)^T$$

Suponha que t é dado por:


$$t = y(\mathbf{x}, \mathbf{w}) + \epsilon$$

ϵ variável aleatória gaussiana

$$p(t|\mathbf{x}, \mathbf{w}, \beta) = \mathcal{N}(t|y(\mathbf{x}, \mathbf{w}), \beta^{-1})$$

$\beta = 1/\sigma^2$ *precisão*

Dado o valor de x ,
o t correspondente tem
uma distribuição gaussiana
com média igual ao valor
 $y(x, \mathbf{w})$



Máxima verossimilhança e mínimos quadrados

Dado conjunto de dados de N entradas $\mathbf{X}$, a verossimilhança (uma função de $\mathbf{w}$ e β)

$$\mathcal{N}(x|\mu, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{1/2}} \exp \left\{ -\frac{1}{2\sigma^2}(x - \mu)^2 \right\}$$

$$p(\mathbf{t}|\mathbf{X}, \mathbf{w}, \beta) = \prod_{n=1}^N \mathcal{N}(t_n | \mathbf{w}^T \phi(\mathbf{x}_n), \beta^{-1})$$

$$\begin{aligned} \ln p(\mathbf{t}|\mathbf{w}, \beta) &= \sum_{n=1}^N \ln \mathcal{N}(t_n | \mathbf{w}^T \phi(\mathbf{x}_n), \beta^{-1}) \\ &= \frac{N}{2} \ln \beta - \frac{N}{2} \ln(2\pi) - \beta E_D(\mathbf{w}) \end{aligned}$$

onde:
$$E_D(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^T \phi(\mathbf{x}_n)\}^2$$

é a Função de Erro de Soma dos Quadrados (SSE) !!!

Maximizar a verossimilhança é equivalente, no que diz respeito à determinação de w , a minimizar a *função de erro da soma dos quadrados*.

A função de erro de soma dos quadrados surgiu como consequência da maximização da probabilidade sob a hipótese de uma distribuição de ruído Gaussiana.

Gradiente da função de erro:

$$E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^T \phi(\mathbf{x}_n)\}^2$$

$$\nabla E(\mathbf{w}) = \sum_{n=1}^N \{\mathbf{w}^T \phi(\mathbf{x}_n) - t_n\} \phi(\mathbf{x}_n)^T$$

Igualando o gradiente a 0:

$$\sum_{n=1}^N t_n \phi(\mathbf{x}_n)^T - \mathbf{w}^T \left(\sum_{n=1}^N \phi(\mathbf{x}_n) \phi(\mathbf{x}_n)^T \right) = 0$$

Isolando $\mathbf{w}$:

$$\mathbf{w} = (\Phi^T \Phi)^{-1} \Phi^T \mathbf{t}$$

Pseudo-inversa de
Moore-Penrose de Φ

as *equações normais* para
o problema de mínimos
quadrados

$$\Phi = \begin{pmatrix} \phi_0(\mathbf{x}_1) & \phi_1(\mathbf{x}_1) & \cdots & \phi_{M-1}(\mathbf{x}_1) \\ \phi_0(\mathbf{x}_2) & \phi_1(\mathbf{x}_2) & \cdots & \phi_{M-1}(\mathbf{x}_2) \\ \vdots & \vdots & \ddots & \vdots \\ \phi_0(\mathbf{x}_N) & \phi_1(\mathbf{x}_N) & \cdots & \phi_{M-1}(\mathbf{x}_N) \end{pmatrix}$$

Design Matrix
 $\Phi_{nj} = \phi_j(\mathbf{x}_n)$

Conexão importante para nos ajudar a entender...

$$\Phi^{\dagger} \equiv (\Phi^T \Phi)^{-1} \Phi^T$$

$\Phi^{\dagger}$ pode ser considerada como uma generalização da noção de matriz inversa para matrizes não quadradas – chamada de ***Pseudo-inversa de Moore-Penrose da matriz Φ***

Se Φ é quadrada e invertível, usando a propriedade $(\mathbf{AB})^{-1} = \mathbf{B}^{-1} \mathbf{A}^{-1}$ vemos que $\Phi^{\dagger} \equiv \Phi^{-1}$.

Observação: estamos usando todo o conjunto de dados de treinamento (N pontos) para obter o $\mathbf{w}$ ótimo (técnica batch)

Aprendizagem sequencial/online

As técnicas batch podem ser computacionalmente caras para conjuntos de dados grandes.

Algoritmos sequenciais : os datapoints são considerados um de cada vez e os parâmetros do modelo são atualizados após cada apresentação.

Descida de gradiente estocástico (ou descida de gradiente sequencial)

$$\mathbf{w}^{(\tau+1)} = \mathbf{w}^{(\tau)} - \eta \nabla E_n$$

E_n é o erro para o ponto n
 $\eta > 0$

Para função de erro de soma de quadrados:

$$\mathbf{w}^{(\tau+1)} = \mathbf{w}^{(\tau)} + \eta (t_n - \mathbf{w}^{(\tau)\top} \phi_n) \phi_n$$

Algoritmo Least-Mean-Squares (LMS)

$$\phi_n = \phi(\mathbf{x}_n)$$

Mínimos Quadrados Regularizados

Ideia : adicionar um termo de regularização a uma função de erro para controlar o ajuste excessivo

$$E_D(\mathbf{w}) + \lambda E_W(\mathbf{w})$$

1. Weight decay (*no aprendizado de máquina*)

$$E_W(\mathbf{w}) = \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

$$\frac{1}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^T \phi(\mathbf{x}_n)\}^2 + \frac{\lambda}{2} \mathbf{w}^T \mathbf{w} \quad (\text{ridge regression nas estatísticas})$$


$$\mathbf{w} = (\lambda \mathbf{I} + \Phi^T \Phi)^{-1} \Phi^T \mathbf{t}$$

equações normais com weight decay

2. Lasso (Least Absolute Shrinkage and Selection Operator)

$$E_W(\mathbf{w}) = \frac{\lambda}{2} \sum_{j=1}^M |w_j|$$

$$\frac{1}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^T \phi(\mathbf{x}_n)\}^2 + \frac{\lambda}{2} \sum_{j=1}^M |w_j| \quad \text{Lasso regression}$$



alguns dos
coeficientes w_j
tornam-se 0, levando
a um modelo esparsos

$$\frac{1}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^T \phi(\mathbf{x}_n)\}^2 + \frac{\lambda}{2} \sum_{j=1}^M |w_j|^q$$

Forma geral de regularização

3. Elastic net

$$E_W(\mathbf{w}) = \frac{\lambda_1}{2} \sum_{j=1}^M |w_j| + \frac{\lambda_2}{2} \mathbf{w}^T \mathbf{w}$$

combina a regularização Lasso e Ridge

Regressão linear para várias saídas

Prever $K > 1$ variáveis de destino - vetor de destino $\mathbf{t}$

A generalização é simples

$$\mathbf{y}(\mathbf{x}, \mathbf{w}) = \mathbf{W}^T \phi(\mathbf{x})$$

$$p(\mathbf{t}|\mathbf{x}, \mathbf{W}, \beta) = \mathcal{N}(\mathbf{t}|\mathbf{W}^T \phi(\mathbf{x}), \beta^{-1}\mathbf{I})$$

$$\begin{aligned} \ln p(\mathbf{T}|\mathbf{X}, \mathbf{W}, \beta) &= \sum_{n=1}^N \ln \mathcal{N}(\mathbf{t}_n|\mathbf{W}^T \phi(\mathbf{x}_n), \beta^{-1}\mathbf{I}) \\ &= \frac{NK}{2} \ln \left(\frac{\beta}{2\pi} \right) - \frac{\beta}{2} \sum_{n=1}^N \|\mathbf{t}_n - \mathbf{W}^T \phi(\mathbf{x}_n)\|^2 \end{aligned}$$

$$\mathbf{W}_{\text{ML}} = (\Phi^T \Phi)^{-1} \Phi^T \mathbf{T} \quad \mathbf{w}_k = (\Phi^T \Phi)^{-1} \Phi^T \mathbf{t}_k = \Phi^\dagger \mathbf{t}_k$$