

Árvores de decisão & Florestas aleatórias

Alberto Paccanaro

EMAp – FGV


www.paccanarolab.org

O material e as imagens nestes slides são de (ou adaptados de):

Gareth, Witten, Hastie, Tibshirani – Uma Introdução ao Aprendizado Estatístico com Aplicações em R, 2013


Algumas imagens são de: *Duda, Hart, Stork – Classificação de padrões, 2006* e *T. Mitchell, Machine Learning, 1996*.

Aula baseada neste livro:




Capítulos 5 e 8
Tree-Based methods

Outras referências relevantes:



DHS 2006

*Excelente livro de referência para aprendizado de máquina
O capítulo das árvores de decisão é lindo ☺*



1996



*Um livro clássico,
muito “CS”*

A ideia

1. Segmente o **espaço de entrada** em regiões.
2. Para prever um novo datapoint: use a média (para *regressão*) ou o rótulo majoritário (para *classificação*) dos pontos de treinamento na região à qual o datapoint pertence.

O conjunto de regras de divisão para segmentar o espaço de entrada pode ser resumido em uma **árvore** → *é simples e útil para interpretação*

Dados dos rebatedores [Years, Hits, **Salary**]



Desenvolvimento das árvores de decisão



Ross Quinlan (CS)

1986: ID3

1992: C4.5

Atualmente: C5.0



Leo Breiman (Estatísticas)

1984: CART

(1996: bagging)

2001: Florestas aleatórias

Statistical Modeling: The Two Cultures



Leo Breiman

Abstract. There are two cultures in the use of statistical modeling to reach conclusions from data. One assumes that the data are generated by a given stochastic data model. The other uses algorithmic models and treats the data mechanism as unknown. The statistical community has been committed to the almost exclusive use of data models. This commitment has led to irrelevant theory, questionable conclusions, and has kept statisticians from working on a large range of interesting current problems. Algorithmic modeling, both in theory and practice, has developed rapidly in fields outside statistics. It can be used both on large complex data sets and as a more accurate and informative alternative to data modeling on smaller data sets. If our goal as a field is to use data to solve problems, then we need to move away from exclusive dependence on data models and adopt a more diverse set of tools.

(Colocarei o trabalho no EClass, caso você esteja interessado).

Árvores de regressão

Exemplo: Dados dos rebatedores [Years, Hits, **Salary**]
queremos prever o salário usando anos e acertos.



- regiões (**retângulos** de alta dimensão, ou “caixas”)
- folhas (nós terminais)
- nós internos

Dois passos

1. Divida o conjunto de valores possíveis para cada feature $X_1, X_2, \dots, X_p$ em j regiões distintas e não sobrepostas, $R_1, R_2, \dots, R_j$ 
2. Para cada observação que caia na região R_j , faça a mesma previsão: a média dos valores de resposta para as observações de treinamento em R_j 

Passo 1: Construindo as regiões

Objetivo: encontrar as caixas $R_1, \dots, R_j$ que minimizam:


$$\sum_{j=1}^J \sum_{i \in R_j} (y_i - \hat{y}_{R_j})^2$$

impraticável considerar todas as partições possíveis...

$\hat{y}_{R_j}$ resposta média para os pontos de treinamento dentro da caixa j

Divisão binária recursiva:

- **top-down:** começa no topo da árvore (todos os pontos estão em uma única região) e divide iterativamente o espaço (cada divisão = dois novos ramos).
- **guloso:** em cada etapa específica fazemos a melhor divisão



A cada passo: selecionamos a feature X_j
e o ponto de corte s

Definimos o par de semiplanos:


$$R_1(j, s) = \{X | X_j < s\}$$

$$R_2(j, s) = \{X | X_j \geq s\}$$

escolhendo j e s que minimizam:

$$\sum_{i: x_i \in R_1(j, s)} (y_i - \hat{y}_{R_1})^2 + \sum_{i: x_i \in R_2(j, s)} (y_i - \hat{y}_{R_2})^2$$

Continuamos o processo até atingir o critério de parada (por exemplo, número máximo de pontos por folha)



Passo 2: fazendo as previsões

(como dissemos alguns slides atrás...)

Para cada observação que caia na região R_j , faça a mesma previsão: a média dos valores de resposta para as observações de treinamento em R_j .

Poda (e overfitting)

Pergunta para você: *o que caracteriza a complexidade de uma árvore? Quais são os “parâmetros” aqui ???*

Uma árvore “grande” irá sobreajustar os dados

“In the extreme but rare case, each leaf corresponds to a single training point and the full tree is merely a convenient implementation of a lookup table; it thus cannot be expected to generalize well in (noisy) problems...” (DHS, section 8.3.3)

A ideia : nós crescemos uma árvore muito grande T_0 e então a podamos de volta para obter uma sub-árvore (*pruning*).

- Dada uma sub-árvore, podemos estimar seu erro de teste usando validação cruzada.
- Mas isso não pode ser feito para todas as subárvores...

O algoritmo de poda, na prática...

Você controla a complexidade da árvore controlando o número total de folhas...

1. todos os pares de nós folha vizinhos (ou seja, aqueles ligados a um nó antecedente comum, um nível acima) são considerados para eliminação.
2. Qualquer par cuja eliminação produz um aumento satisfatório (pequeno) no desempenho no conjunto **de validação cruzada** é eliminado e o nó antecedente comum declarado uma folha.

Estude o algoritmo 8.1 do livro de Tibshirani

Árvores de classificação

Como, para uma região, pretendemos prever a classe mais comum naquela região, precisamos “quantificar” com que frequência os pontos não pertencem a essa classe.

Pureza do nó

Índice Gini:


$$G = \sum_{k=1}^K \hat{p}_{mk}(1 - \hat{p}_{mk})$$

Entropia:

$$D = - \sum_{k=1}^K \hat{p}_{mk} \log \hat{p}_{mk}$$

$\hat{p}_{mk}$ representa a proporção de observações de treinamento na região m que são da classe k .

Valor pequeno se todos $\hat{p}_{mk}$ estiverem próximos de 0 ou 1.



Entropia de uma variável binária quando a proporção de positivos varia entre 0 e 1 (uso $\log_2$)

Ganho de informação/ganho de Gini

Precisamos quantificar a diferença no índice de entropia ou Gini entre *antes* e *depois* da divisão.

$$Gain(S, X_j) \equiv Entropy(S) - \sum_{v \in values(X_j)} \frac{|S_v|}{|S|} Entropy(S_v)$$

onde: S é um conjunto de pontos, $values(X_j)$ é o conjunto de valores possíveis para X_j e S_v é o subconjunto de S para o qual X_j tem valor v

$Gain = (Entropy \text{ of the parent node}) - (average \text{ entropy of the child nodes})$

Uma fórmula equivalente pode ser escrita para o índice de Gini.

Vantagens importantes das Árvores de Decisão a serem lembradas


- Árvores → *intepretável*
 - podemos interpretar a decisão para qualquer padrão particular como a conjunção de decisões ao longo do caminho para seu nó folha correspondente.
 - ocasionalmente podemos obter interpretações claras das categorias, criando descrições lógicas usando conjunções e disjunções
- Pode lidar com *missing data* (dados ausentes)
- Pode lidar com valores numéricos
- Pode lidar com valores nominais
- Pode lidar com uma mistura de valores numéricos e nominais

Ensemble Methods

1. Bagging
2. Boosting

O Bootstrap

Um método para quantificar a incerteza associada a um determinado estimador.



1. Bagging – Bootstrap Aggregation

Um procedimento de propósito geral para melhorar o desempenho de qualquer método de aprendizagem

A média de um conjunto de observações reduz a variância -- dado um conjunto de n observações independentes $Z_1, \dots, Z_n$, cada um com variância σ^2 , a variância da média $\bar{Z}$ das observações é σ^2/n

IDEIA:

- usar o bootstrap para obter muitos conjuntos de treinamento
- construir um modelo de previsão separado usando cada conjunto de treinamento
- média das previsões.

$$\hat{f}_{\text{bag}}(x) = \frac{1}{B} \sum_{b=1}^B \hat{f}^{*b}(x)$$

onde $\hat{f}^{*b}(x)$ é obtido por treinamento na amostra bootstrap b .

Para regressão: média das previsões

Para classificação: obter uma votação majoritária

Ótimos resultados quando aplicados em
Árvores de Decisão – **BAGGED TREES**

Truque ao bagging... o erro OOB

Estime o erro de teste de um modelo bagged, sem validação cruzada ou conjunto de validação! 😊

Cerca de um terço dos datapoint não é usado para ajustar um determinado modelo.

Out-of-bag (OOB) datapoints: aqueles não usados para o aprendizado do modelo.

Podemos prever a resposta para o datapoint i usando cada um dos modelos em que esse datapoint foi OOB.

Florestas Aleatórias

*Árvores bagged com um truque para
descorrelacionar as árvores 😊*

Um problema com bagged trees: se uma feature é um preditor forte, a maioria das árvores será semelhante.

➔ As previsões serão altamente correlacionadas...

... como antes, a média de muitas quantidades altamente correlacionadas não leva a uma redução tão grande na variância quanto a média de muitas quantidades não correlacionadas...

Portanto, o bagging não é tão eficaz...

As florestas aleatórias forçam cada divisão a considerar apenas um subconjunto dos preditores:

- construímos uma série de árvores de decisão em amostras de treinamento bootstrap (ou seja, fazemos bagging)
- construindo as árvores de decisão: **em cada divisão, uma amostra aleatória de m features é escolhida** como candidata a divisão do conjunto completo de p features (tipicamente $m \approx \sqrt{p}$).

Portanto, estamos decorrelacionando as árvores!

Importante: esse é um dos melhores algoritmos de aprendizado que existem!!! 😊 TENHA ISSO EM MENTE!